



07 트랜스포머 2

BERT(Bidirectional Encoder Representation from Transformer)

- 2018년 구글에서 발표한 언어 모델
 - 트랜스포머 기반 양방향 인코더 사용
 - Bidirectional 인코더 : 입력 시퀀스를 양쪽 방향에서 처리
 - 이전 & 이후의 단어를 모두 참조해 단어의 의미와 문맥 파악
- 전이 학습에 주로 활용(← 대규모 데이터 사용해 사전 학습)
 - 적은 양의 데이터로 높은 정확도 / 학습 시간 단축




그림 7.13 트랜스포머와 BERT 모델 비교

- 트랜스포머의 인코더 모듈만을 사용해 입력 문장을 처리
 - 단어들을 임베딩 - 각 의미 벡터화 - 순차적 처리 - 문장 의미 추출
- 입력 문장의 단어를 좌우 양방향으로 처리 - 문맥 정보를 모델링
- 사전 학습에 마스킹된 언어 모델링(MLM) & 다음 문장 예측 방법(NSP) 사용

사전 학습 방법

1. 마스킹된 언어 모델링(Masked Language Modeling, MLM)

- 입력 문장에서 임의로 일부 단어를 마스킹 & 해당 단어를 예측
- 누락된 단어를 추론하는 능력
- 문장 전체 의미를 이해하는 능력 향상

2. 다음 문장 예측(Next Sentence Prediction, NSP)

- 두 번째 문장이 첫 번째 문장의 다음에 오는 문장인지 여부를 판단
- 입력 문장에 특수한 토큰들을 추가 → 학습/추론 과정에서 필요한 정보를 제공
- [CLS] 토큰, [SEP] 토큰, [MASK] 토큰이 활용

1)[CLS] 토큰

- 입력의 시작 부분에 추가
- 문장 분류 작업을 위한 정보 제공
- 입력 문장이 어떤 유형의 문장인지 파악 가능

2)[SEP] 토큰

- 입력 문장 내에서 두 개 이상의 문장을 구분하기 위해 사용되는 토큰
- 입력 문장을 두 개의 독립적인 문장으로 인식, 각각의 문장의 정보를 파악 가능

3)[MASK] 토큰

- 입력 문장 내에서 임의로 선택된 단어를 가리키는 특별한 토큰
- 일부 단어를 가린 후 학습 & 예측에 사용






그림 7.14 BERT 모델의 입력 임베딩과 손실 함수

BART(Bidirectional Auto-Regression Transformer)

- 2019년 메타의 FAIR 연구소에서 발표한 트랜스포머 기반 모델
- BERT의 인코더와 GPT의 디코더를 결합한 시퀀스-시퀀스 구조로 노이즈 제거 오토인코더로 사전 학습됨
 - 입력 데이터에 잡음 추가, 잡음 없는 원본 데이터로 복원하도록 학습
- 사전 학습 시 BERT의 인코더 & GPT의 디코더가 학습하는 방법을 일반화



- BERT - 인코더만 사용 / BART - 인코더 & 디코더 모두 사용



사전 학습 방법

- BERT의 마스킹된 언어 모델링(MLM) 외에도 다양한 노이즈 기법 사용
- 토큰 마스킹 기법, 토큰 삭제, 문장 교환, 문서 회전, 텍스트 채우기 기법 사용

원본 문장	노이즈 기법
	토큰 마스킹 그는 _ 발을 옮겼다. _ 아내는 멀어지는 그를 _있었다. 그녀는 눈물을 _ 그도 _었다.
	토큰 삭제 그는 발을 옮겼다. 아내 멀어지는 그를 있었다. 그녀는 눈물을 , 그도 .었다.
	문장 순열 그녀는 눈물을 흘렸다. 그는 정문으로 발을 옮겼다. 그의 아내는 멀어지는 그를 바라보고 있었다. 그도 마찬가지로였다.
	문서 회전 그를 바라보고 있었다. 그녀는 눈물을 흘렸다. 그도 마찬가지로였다. 그는 정문으로 발을 옮겼다. 아내는 멀어지는
	텍스트 채우기 그는 옮겼다. 아내는 멀어지는 그를 , 그녀는 눈물을 흘렸다. 그도 .

1. 토큰 마스킹(Token Masking)

- MLM과 동일한 기법
- 입력 문장의 일부 토큰을 마스크 토큰으로 치환
- 문장 내에서 어떤 단어가 중요한 역할을 하는지 학습 가능
- 입력 문장의 문맥을 이해하고, 문장 내에서 중요한 정보를 추출하는 능력이 향상

2. 토큰 삭제(Token Deletion)

- 입력 문장의 일부 토큰을 치환 X, 삭제 O
- 토큰 마스킹과 다르게, 어떤 위치의 토큰이 삭제되었는지 맞춰야 함
- 입력 문장에서 불필요한 정보나 중요하지 않은 정보를 자동으로 필터링해 처리
- 모델 학습 & 예측 시간 감소, 일반화 성능 향상\

3. 문장 순열(Sentence Permutation)

- 마침표 기준으로 문장 나누고, 문장의 순서 섞는 방법
- 문장 내에서 단어들이 어떻게 연결되어 있는지 잘 파악
- 입력 문장이 다른 순서로 주어졌을 때 잘 처리 가능

4. 문서 회전(Document Rotation)


- 임의의 토큰으로 문서가 시작(< 문장의 순서는 유지)
- 모델이 문서의 시작점을 인식하도록 함

5. 텍스트 채우기(Text Infilling)

- 몇 개의 토큰을 하나의 구간(span)으로 묶고, 일부 구간을 마스크 토큰으로 대체
- 묶은 구간의 길이(개수)는 0~임의의 값까지 설정
- 포아송(Poisson distribution) 분포로 구간을 나눔
 - 람다 값을 3으로 설정해 계산
 - 구간의 길이가 0 - 해당 위치에 변환된 토큰이 없다

미세 조정 방법

- 다운스트림 작업에 맞게 입력 문장을 구성
 - 인코더와 디코더에 다른 문장 구조로 입력



- **문장 분류 작업**
 - 입력 문장을 인코더와 디코더에 동일하게 입력
 - 디코더의 마지막 토큰 은닉 상태를 선형 분류기의 입력값으로 업
- **토큰 분류 작업**
 - 입력 문장을 인코더와 디코더에 동일하게 입력
 - 디코더의 각 시점별 마지막 은닉 상태를 토큰 분류기의 입력값으로 사용
- **추상적 질의응답(Abstractive Question Answering) & 문장 요약(Summarization)**


- 추상적 질의응답 : 입력값 조작해 출력
 - 문장의 의미를 파악, 새로운 문장 생성 가능
 - 학습 단계
 1. 새로 추가된 트랜스포머 인코더의 가중치, 위치 임베딩, 첫 번째 인코더층의 셀프 어텐션 입력 행렬 가중치만 학습
 2. 모든 신경망의 가중치를 작은 반복으로 학습
- ✨ 문장 내부의 토큰 사이의 상관관계를 파악해 문장의 의미 정확하게 이해 가능!

ELECTRA(Efficiently Learning an Encoder that Classifiers Token Replacements Accurately)

- 2020년 구글에서 발표한 트랜스포머 기반의 모델
- 입력을 마스킹하는 대신, 생성자(Generator, 변환기 모델), 판별자(Discriminator, 변환기 모델) 사용해 사전 학습 수행
- 생성자 & 판별자 학습 - 생성적 적대 신경망(GAN)과 유사한 방법으로 학습 수행
- 모델 학습 속도 빠름
- 자연어 생성 작업에서 자연스러운 문장 형성 가능
- 모델 매개변수 수가 적음
- 적은 메모리 사용량

사전 학습 방법

- 트랜스포머 인코더 구조 따름
 - 생성자 모델
 - 입력 문장의 일부 토큰을 마스크 처리
 - 마스크 처리된 토큰이 원래 어떤 토큰이었는지 예측하며 학습
 - 판별자 모델
 - 각 입력 토큰이 원본 문장의 토큰인지 or 생성자 모델로 인해 바뀐 토큰인지 맞추기
- ⇒ **RTD(Replaced Token Detection)** 학습 방법




• 생성적 적대 신경망(GAN)과의 차이점

1. 생성자 모델이 원래 토큰을 정확히 예측한 경우, 이 토큰은 생성된 토큰이 아닌 원본 토큰으로 인식
 2. 1) GAN - 생성 모델과 판별 모델을 적대적으로 학습
 - a. 생성 모델 : 판별 모델이 실제 데이터와 구분하기 어렵게 학습
 - b. 판별 모델 : 실제 데이터와 생성된 데이터를 더욱 잘 구분하게 학습
 - 2) ELECTRA
 - a. 생성 모델 : 마스킹된 언어 모델을 통해 학습
 - b. 판별 모델 : 각 토큰이 바뀐 토큰인지 or 원본 토큰인지를 구분하도록 학습
 3. 생성 모델 & 판별 모델 : 트랜스포머 인코더 구조를 따름
 - 두 모델이 같은 개수의 계층으로 구성
 - 가중치 공유 가능 - 빠른 학습
 - 생성 모델의 성능이 너무 높아져 판별 모델이 학습 불가
 - ELECTRA
 - 생성 모델을 판별 모델의 1/2~1/4 크기로 바꾸어 설정
 - 모든 가중치를 공유하는 대신, 임베딩 계층의 가중치만 공유
- ⇒ 판별 모델이 학습하기 적합한 생성 모델을 유지하면서 가중치를 공유 - 효율적인 학습

T5(Text-to-Text Transfer Transformer)

- 2019년 구글에서 발표한 자연어 처리 분야의 딥러닝 모델, 트랜스포머 구조를 기반으로 함
- 인코더-디코더 모델 구조를 바탕으로 GLUE, SuperGLUE, CNN/DM(Cable News Network/Daily Mail) 등의 데이터세트에서 SOTA(State-of-the-art) 달성
- 다양한 자연어 처리 작업에서 높은 성능
- 입력과 출력을 모두 토큰 시퀀스로 처리하는 Text-to-Text 구조
- 입력과 출력의 형태를 자유롭게 다룸

- 모델 구조상 유연성과 확장성 뛰어남 → 새로운 자연어 처리 작업에 쉽게 적용 가능
- 문장 번역, 요약, 질의응답, 텍스트 분류



- 입력과 출력이 모두 토큰(텍스트) 시퀀스 - 입력과 출력 간의 관계를 더욱 세밀히 다룸
- 사전 학습 후 미세 조정 단계에서 해당 작업의 데이터를 이용해 모델을 조정 - 최적의 성능
- CoLA 데이터셋 - 문법적으로 허용 가능한 문장 & 그렇지 않은 문장을 구분 가능
- STS-B 데이터 세트를 이용 - 문장 간 의미적 유사성 측정 가능
- 학습을 위한 데이터셋은 원본 문장과 대상 문장을 사용
- C4(Colossal Clean Crawled Corpus) 데이터셋을 활용해 다양한 언어 처리 작업을 수행
- 사전 학습 방식 - 비지도 학습 방식으로 입력 문장의 일부 구간을 마스킹해 입력 시퀀스를 처리
 - **센티널 토큰(Sentinel Token)** 사용